Inteligencia Artificial. Guía de estudio 1

Tomas Santana

Octubre 2026

1 Guía de estudio: clases 1 a 4

Esta guía reúne preguntas sobre los conceptos fundamentales estudiados en las primeras cuatro clases. Su propósito es orientar el estudio personal y ayudar a relacionar los conceptos vistos en clase. No es una actividad evaluada ni requiere entrega. Se recomienda intentar responder las preguntas con palabras propias, explicando el significado de los conceptos y de los símbolos matemáticos cuando corresponda.

1.1 Parte 1. Fundamentos matemáticos

1. ¿Qué es un vector y qué es una matriz? Explica cómo utilizarías un vector para representar las características de una casa y cómo organizarías los datos de varias casas en una matriz.
2. ¿Qué es el producto punto de dos vectores y qué tipo de resultado produce? Explica cómo aparece esta operación al calcular una predicción mediante $\theta^T x$, y como se relaciona con la ecuación de la recta.
3. ¿Qué representa la derivada de una función en un punto? ¿Qué información proporciona el signo de la derivada y cómo puede ayudarnos a encontrar el mínimo de una función?

1.2 Parte 2. Aprendizaje supervisado y regresión lineal

4. ¿Qué significa aprendizaje supervisado? Explica qué son una característica (feature) y una etiqueta (label), y cuál es la diferencia entre un problema de regresión y uno de clasificación. Da un ejemplo de cada uno.
5. En un conjunto de entrenamiento de pares $\left(x^{(i)}, y^{(i)}\right)$, ¿qué representan $x^{(i)}$, $y^{(i)}$ y el superíndice (i)? ¿Qué diferencia existe entre el valor real $y^{(i)}$ y la predicción $h_{\theta(x^{(i)})}$?
6. Considera el modelo $h_{\theta(x)} = \theta_0 + \theta_1 x$. ¿Qué representan x, $h_{\theta(x)}$, θ_0 y θ_1? Explica qué ocurriría con las predicciones si modificáramos uno de los parámetros, manteniendo el mismo valor de entrada.
7. ¿Qué significa entrenar un modelo de regresión lineal? ¿Cuáles son los valores que intentamos encontrar durante el entrenamiento y cuáles son los datos que mantenemos fijos?
8. ¿Qué es una función de costo y para qué se utiliza? Explica qué mide el error cuadrático y por qué buscamos parámetros que reduzcan ese error.
9. ¿En qué consiste el descenso por gradiente? Explica qué papel desempeñan el gradiente y la tasa de aprendizaje α, y por qué este procedimiento permite ajustar los parámetros de un modelo.
10. ¿Qué son las ecuaciones normales en regresión lineal? Explica qué problema resuelven y cuál es su principal diferencia con el descenso por gradiente.

1.3 Parte 3. Generalización, selección de modelos y regularización

11. ¿Qué significa que un modelo generalice correctamente? Explica por qué obtener un error muy bajo sobre los datos de entrenamiento no garantiza que el modelo funcione bien con datos nuevos.

12. ¿Para qué sirven los conjuntos de entrenamiento, validación y prueba? Explica qué decisiones deberíamos tomar con cada uno y por qué no conviene utilizar el conjunto de prueba para escoger un modelo.
13. ¿Qué son el sobreajuste (overfitting) y el subajuste (underfitting)? Explica cómo se relacionan con la complejidad de un modelo y con sus errores de entrenamiento y validación.
14. ¿Qué es la regularización y qué problema busca resolver? Explica la diferencia principal entre Ridge (L_2) y Lasso (L_1), qué controla el hiperparámetro λ y en qué se diferencia un hiperparámetro de un parámetro aprendido.

1.4 Parte 4. Clasificación y regresión logística

15. ¿Por qué no siempre resulta conveniente usar regresión lineal para resolver un problema de clasificación binaria? Explica qué tipo de salida queremos obtener y qué dificultades puede presentar una predicción lineal sin restricciones.
16. En un clasificador lineal, ¿qué representa el score $\theta^T x$? ¿Qué es la frontera de decisión y cómo determina el modelo a qué clase asignar una observación?
17. ¿Qué es la función sigmoide y para qué se utiliza en regresión logística? Explica por qué aplicarla al score permite interpretar la salida como una probabilidad.
18. Si un modelo de regresión logística devuelve $h_{\theta(x)} = 0.8$, ¿cómo interpretas ese resultado? ¿Qué clase predecirías utilizando un umbral de 0.5? Explica también, en términos generales, qué buscamos al entrenar este modelo mediante máxima verosimilitud.