

Inteligencia Artificial. Tarea 1

Tomas Santana

September 26, 2026

1. Descargar un dataset en [Kaggle.com](https://www.kaggle.com) (o cualquier otra fuente) con al menos 500 ejemplos y al menos 2 características predictoras continuas y una variable objetivo continua. Realizar un análisis exploratorio de los datos, y limpiar los datos según sea necesario. Para ello, pueden utilizar `pandas`, `numpy`, y `matplotlib` o `seaborn`. Importante: el dataset a utilizar debe ser de datos reales, no generado artificialmente. La descripción del dataset usualmente especifica el origen de los datos. (5 puntos)
2. Implementar en Python una clase que implemente la solución analítica de la regresión lineal multivariable, siguiendo la ecuación normal:

$$\theta = (X^T X)^{-1} X^T y$$

La clase debe tener los siguientes métodos:

- `fit(X, y)`: Ajusta el modelo a los datos de entrenamiento.
- `predict(X)`: Realiza predicciones sobre nuevos datos.
- `mse(y_true, y_pred)`: Calcula el error cuadrático medio entre los valores verdaderos y las predicciones.
- `r2_score(y_true, y_pred)`: Calcula el coeficiente de determinación R^2 entre los valores verdaderos y las predicciones.

Les recomiendo ver [este video de StatQuest sobre el coeficiente de determinación](#). Su implementación puede estar basada en la función `r2_score` de `sklearn`. Pueden leer también [la documentación del método](#).

Como atributos de la clase, deben incluirse los parámetros del modelo θ (usar `b_` siguiendo la convención de `sklearn`) y el intercepto θ_0 (usar `intercept_` siguiendo la convención de `sklearn`). (6 puntos)

Ejemplo de uso de la clase:

```
from my_linear_regression import MyLinearRegression
import numpy as np

# Crear datos de ejemplo
df = pd.read_csv("ruta_al_dataset.csv")
X = df[["feature1", "feature2"]].values
y = df["target"].values

# Crear instancia de la clase
model = MyLinearRegression()

# Entrenar el modelo
model.fit(X, y)

# Realizar predicciones
predictions = model.predict(X)
```

3. Utilizar la clase implementada para entrenar un modelo de regresión lineal multivariable con el dataset descargado en el punto 1. Entrenar con los mismos datos la clase `LinearRegression` de `sklearn` y comparar los resultados obtenidos con ambas implementaciones. Comparar las métricas de desempeño (MSE y R^2). Comparar los valores de los parámetros (las propiedades `coef_` y `intercept_`) del modelo obtenidos con ambas implementaciones. (5 puntos)
4. Preguntas de análisis conceptual y discusión (4 puntos):
 - 4.1. Partición de datos y validación: Por qué es fundamental evaluar el modelo sobre un conjunto de prueba que no haya sido utilizado durante el ajuste (`fit`)? Explique qué riesgo se corre al reportar únicamente las métricas calculadas sobre los datos de entrenamiento y cómo se relaciona esto con el dilema sesgo-varianza. (2 puntos)
 - 4.2. Diagnóstico de sesgo y varianza: Analice el desempeño obtenido (R^2 y MSE) tanto en el conjunto de entrenamiento como en el de prueba. ¿Considera que su modelo sufre de **alto sesgo** (underfitting) o **alta varianza** (overfitting)? Justifique su respuesta teniendo en cuenta la complejidad del modelo (lineal) frente a la naturaleza del dataset elegido. (2 puntos)